RELATÓRIO EXECUTIVO

Classificação da Qualidade dos Vinhos

Kamila Karina Gomes (rm376138)
FIAP | PÓS TECH — DATA ANALYTICS
Novembro de 2026

1. Sumário Executivo

A análise das amostras do Wine Quality Dataset identificou características físico-químicas associadas à classificação de qualidade dos vinhos, com destaque para o teor alcoólico, os sulfatos, o ácido cítrico e a acidez volátil.

Entre os modelos avaliados, o Random Forest apresentou os melhores resultados gerais. Entretanto, a avaliação mostrou que reconhecer vinhos de alta qualidade continua sendo um desafio, mesmo após a aplicação de técnicas para balancear as classes.

Os resultados apontam oportunidades para utilizar dados como apoio ao acompanhamento da qualidade e à avaliação especializada.

A análise não busca estabelecer uma fórmula única para definir um bom vinho, mas ampliar as informações disponíveis para apoiar decisões.

2. Contexto e objetivo

2.1. Contexto

A qualidade dos vinhos é um aspecto importante para a indústria vitivinícola e sua avaliação tradicionalmente envolve análises sensoriais realizadas por especialistas.

Com o avanço da ciência de dados, as características físico-químicas dos vinhos também podem ser exploradas para identificar padrões associados às avaliações de qualidade, oferecendo uma perspectiva complementar ao processo tradicional de avaliação.

2.2. Objetivo

Investigar quais características físico-químicas apresentam maior associação com a qualidade dos vinhos e avaliar a capacidade de modelos de aprendizado de máquina em identificar amostras classificadas como de média/baixa e alta qualidade.

A partir dos resultados, buscamos identificar oportunidades para utilizar essas informações como apoio ao monitoramento e à avaliação da qualidade na produção.

2.3. Pergunta central

O que diferencia os vinhos de alta qualidade?

O objetivo não é produzir vinhos iguais, mas utilizar melhor as informações disponíveis para compreender e acompanhar sua qualidade.

3. Conhecendo os dados

A análise utiliza o Wine Quality Dataset, uma base de dados que reúne amostras de vinhos e suas respectivas características físico-químicas, acompanhadas de avaliações de qualidade realizadas por especialistas.

Após a preparação dos dados, foram consideradas 1143 amostras e 11 variáveis preditoras, relacionadas a aspectos como acidez, teor alcoólico, densidade e concentração de diferentes componentes químicos.

A variável original *"quality"*, que representa a nota atribuída ao vinho, foi transformada em uma classificação binária (*"quality_classification"*), criada durante o projeto:

- **Média/Baixa qualidade (0):** notas inferiores a 7.
- **Alta qualidade (1):** notas iguais ou superiores a 7.

A identificação das amostras foi mantida na coluna *"Id"*, utilizada como referência, mas não considerada uma variável preditora nos modelos.

As verificações iniciais não identificaram valores ausentes ou registros duplicados, indicando que a base não demandou tratamentos relacionados a essas ocorrências antes da análise exploratória.

4. Análises | Storytelling

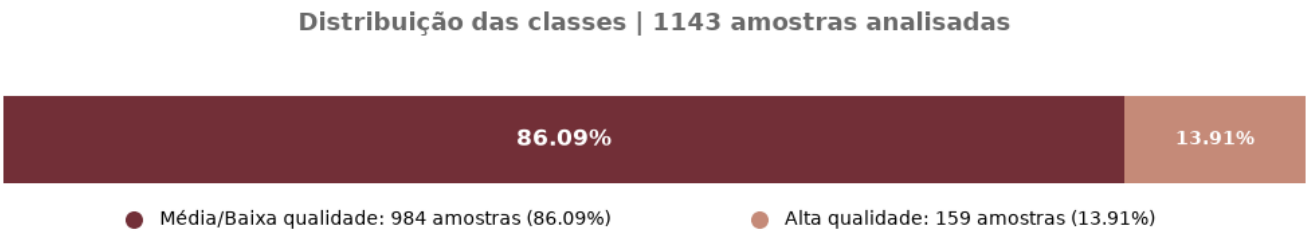
4.1. A alta qualidade representa uma parcela minoritária das amostras

A distribuição das classificações revela uma diferença significativa entre as amostras analisadas.

Das 1143 amostras, 984 (86.09%) foram classificadas como de média/baixa qualidade, enquanto 159 (13.91%) receberam classificação de alta qualidade.

Isso significa que, para cada vinho classificado como de alta qualidade, existem aproximadamente seis classificados como de média/baixa qualidade na base analisada.

Essa diferença merece atenção, pois a menor quantidade de exemplos de alta qualidade pode dificultar sua identificação pelos modelos preditivos.



4.2. As características dos vinhos apresentam diferentes padrões de distribuição

As amostras analisadas apresentam comportamentos distintos em relação às suas características físico-químicas.

Algumas variáveis, como açúcar residual, cloretos e dióxido de enxofre, concentram grande parte das amostras em faixas menores, mas também apresentam registros em valores mais elevados. Outras, como densidade e pH, possuem distribuições mais concentradas em torno de determinadas faixas.

Além dos diferentes padrões de distribuição, as variáveis apresentam escalas de valores distintas. Enquanto algumas possuem intervalos de variação mais estreitos, outras abrangem faixas consideravelmente maiores. Por esse motivo, os gráficos utilizam escalas individuais, permitindo visualizar melhor o comportamento de cada característica.

Essa variação também aparece nos boxplots, que evidenciam observações mais afastadas da concentração principal em diferentes características.

Os resultados mostram que as amostras possuem diferentes perfis físico-químicos e que cada variável apresenta uma distribuição própria.

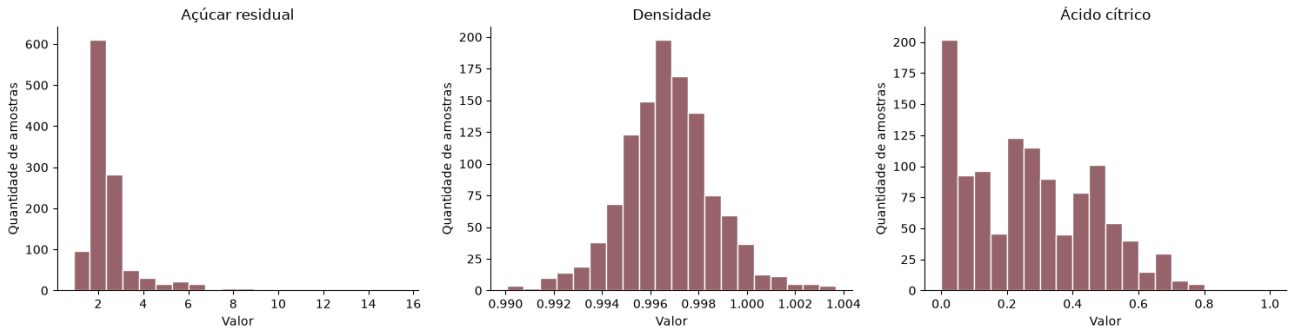


Figura 1 - Distribuição das características físico-químicas selecionadas

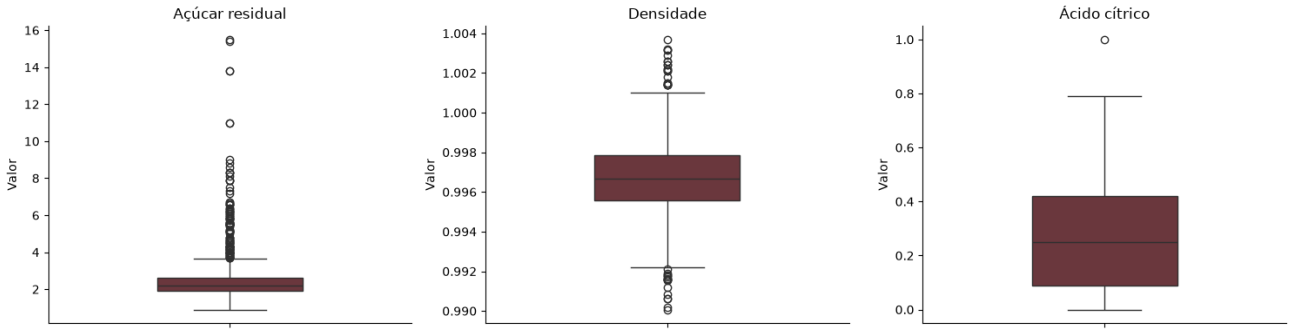


Figura 2 - Dispersão e valores extremos das características selecionadas

4.3. Algumas características apresentam maior associação com a qualidade

Entre as características analisadas, o teor alcoólico e a acidez volátil foram as que mais se destacaram na relação com a qualidade dos vinhos.

As amostras com maior teor alcoólico apresentaram uma tendência maior de serem classificadas como de alta qualidade. Já aquelas com níveis mais elevados de acidez volátil apareceram mais frequentemente entre os vinhos classificados como de média/baixa qualidade.

O ácido cítrico e os sulfatos também apresentaram relações positivas com a classificação, embora menos expressivas.

Esses resultados indicam que algumas características físico-químicas podem oferecer sinais importantes para compreender as diferenças entre os vinhos avaliados, contribuindo para uma análise mais direcionada de sua qualidade.

Ressalva metodológica: as relações observadas não significam que alterar isoladamente uma dessas características resultará em uma mudança na qualidade do vinho.

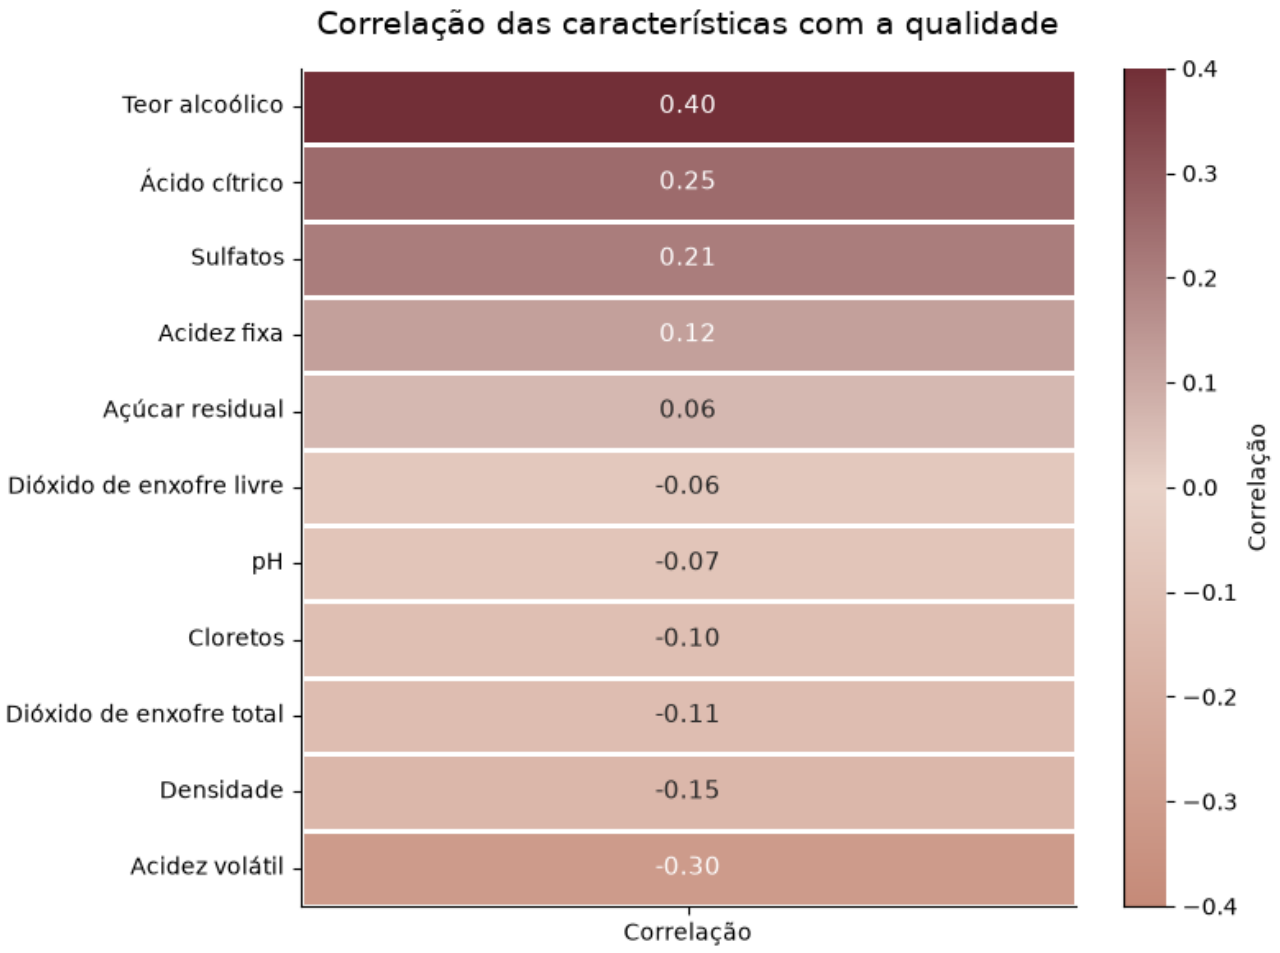


Figura 3 - Correlação entre as características físico-químicas e a classificação de qualidade

4.4. Os principais indicadores também se destacam no modelo preditivo

Os resultados do modelo preditivo reforçam alguns dos padrões identificados durante a análise das características dos vinhos.

Teor alcoólico, sulfatos, ácido cítrico e acidez volátil também se destacaram entre as características mais relevantes utilizadas pelo modelo para realizar suas previsões.

Essa proximidade entre os resultados indica que essas características oferecem informações importantes para diferenciar as amostras de acordo com a classificação de qualidade.

Para as vinícolas, esse resultado aponta um conjunto de características que merece atenção no acompanhamento e na avaliação dos vinhos, sem que isso represente uma fórmula única para definir sua qualidade.

Nota: a importância representa a contribuição das variáveis para as previsões do modelo, não uma medida de influência causal sobre a qualidade.

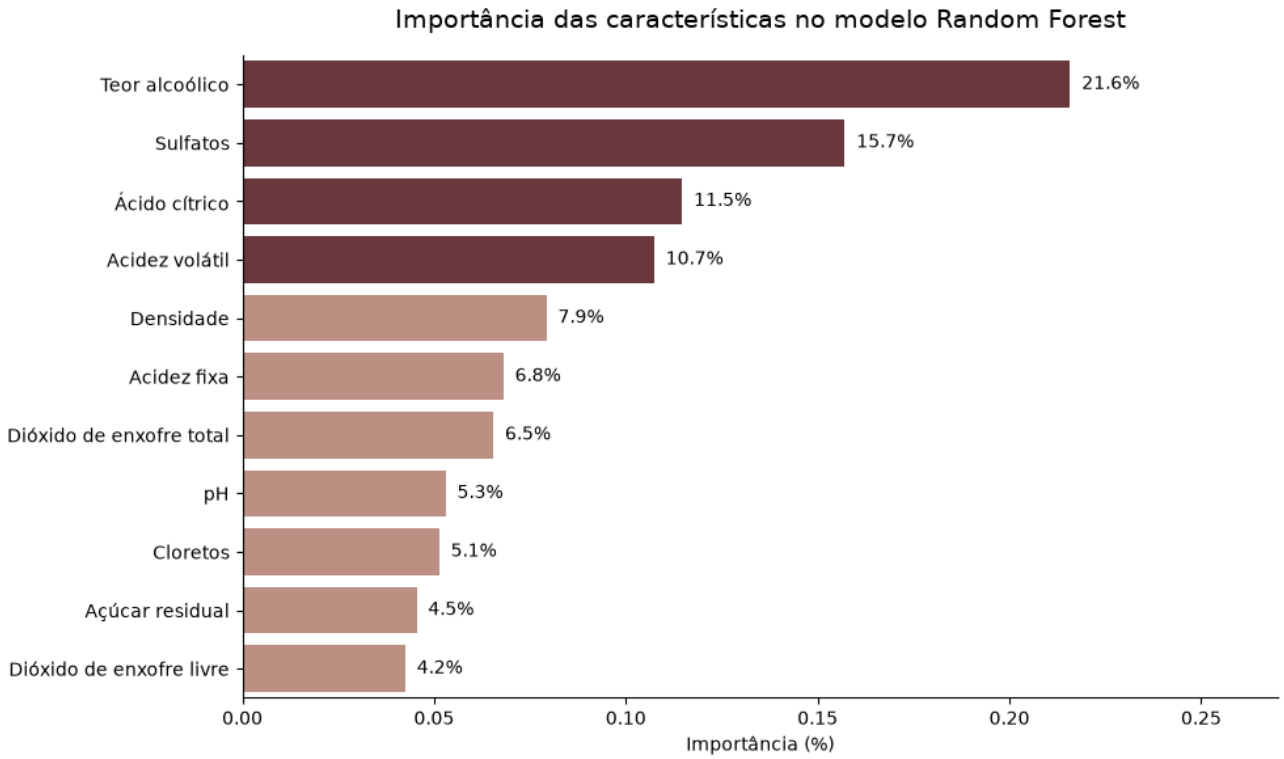


Figura 4 - Importância relativa das características nas previsões do modelo Random Forest

4.5. Identificar vinhos de alta qualidade continua sendo um desafio

Entre os modelos avaliados, o Random Forest apresentou os melhores resultados gerais, com desempenho ligeiramente superior após a aplicação do oversampling, técnica utilizada para balancear a quantidade de amostras entre as classes.

Entretanto, a análise das previsões revelou um ponto importante: mesmo com a melhora dos indicadores gerais, o modelo não aumentou sua capacidade de identificar vinhos de alta qualidade. Sem o balanceamento, foram identificadas corretamente 21 das 32 amostras dessa categoria. Com o oversampling, esse número passou para 19.

Por outro lado, a versão balanceada apresentou menos classificações incorretas de vinhos de média/baixa qualidade como sendo de alta qualidade.

Os resultados mostram que, embora as características físico-químicas permitam identificar padrões associados à qualidade, reconhecer vinhos de alta qualidade continua sendo um desafio.

Para as vinícolas, essas informações podem contribuir para o acompanhamento das características dos produtos e apoiar avaliações mais direcionadas. Ainda assim, a análise deve ser utilizada como complemento à experiência dos especialistas, considerando que a qualidade de um vinho não se resume a um conjunto de indicadores físico-químicos.

Comparação dos modelos

Modelos sem oversampling

Modelo	Macro F1	F1 classe 1	F1 classe 0	Acurácia
Regressão Logística	0.68	0.49	0.88	0.80
SVC	0.70	0.52	0.89	0.82
Random Forest	**0.78**	**0.63**	**0.94**	**0.89**
KNN	0.70	0.47	0.92	0.86

Modelos com oversampling

Modelo	Macro F1	F1 classe 1	F1 classe 0	Acurácia
Regressão Logística	0.69	0.49	0.88	0.80
SVC	0.70	0.52	0.89	0.82
Random Forest	**0.80**	**0.64**	**0.95**	**0.91**
KNN	0.70	0.52	0.87	0.80

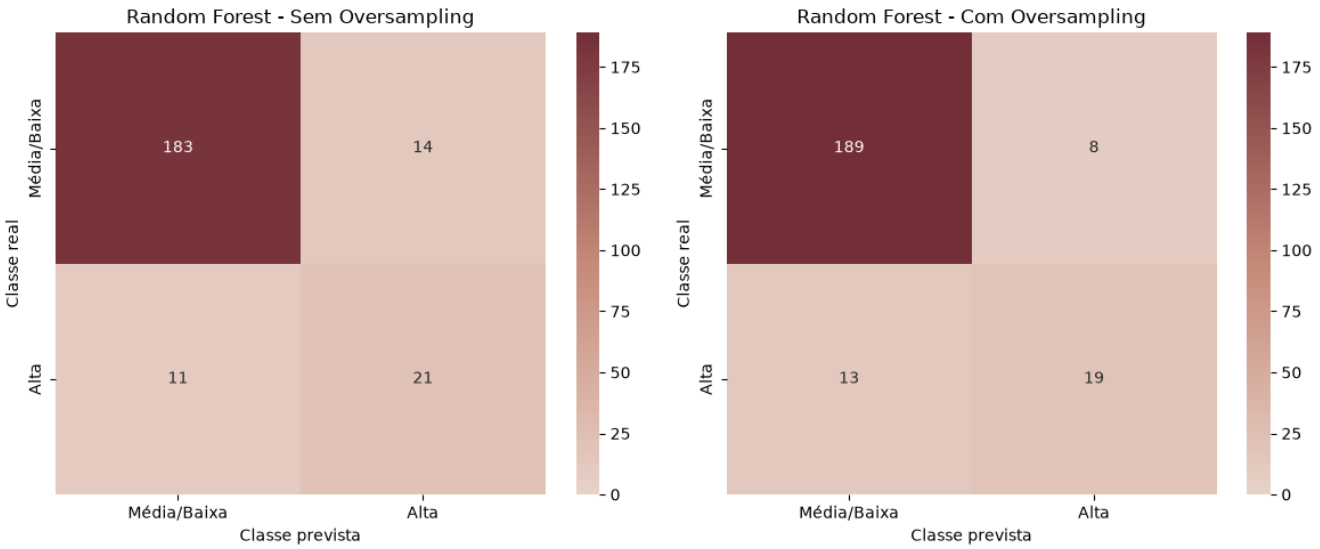


Figura 5 - Comparação das classificações do Random Forest com e sem oversampling

Nota: As linhas representam as classes reais e as colunas, as classes previstas. Os valores indicam a quantidade de amostras em cada combinação.

5. Oportunidades para o negócio: dados como apoio à avaliação da qualidade

Os resultados da análise apontam oportunidades para utilizar dados como recursos complementares no acompanhamento e na avaliação da qualidade dos vinhos.

- **Acompanhamento da qualidade:** observar características como teor alcoólico, acidez volátil, ácido cítrico e sulfatos, que apresentaram maior associação com a classificação.
- **Apoio aos especialistas:** utilizar os padrões identificados para direcionar avaliações e aprofundar a análise de determinadas amostras.
- **Apoio à tomada de decisão:** combinar informações físico-químicas, previsões dos modelos e avaliações sensoriais para ampliar os subsídios disponíveis durante o acompanhamento da produção.

A oportunidade não está em estabelecer um padrão único de qualidade, mas em utilizar os dados para compreender melhor os vinhos e apoiar a experiência dos especialistas.

6. Conclusões e limitações

O estudo permitiu identificar características físico-químicas que apresentam maior associação com a qualidade dos vinhos, evidenciando padrões que podem contribuir para uma compreensão mais ampla das diferenças entre as amostras.

Entre os modelos avaliados, o Random Forest apresentou o melhor desempenho geral. Ainda assim, os resultados demonstraram que reconhecer vinhos de alta qualidade continua sendo um desafio, indicando que as informações disponíveis não são suficientes para determinar sua qualidade de forma isolada.

Os resultados também devem ser considerados dentro do contexto da base analisada, que representa um conjunto específico de amostras e não necessariamente reflete todo o mercado. Além disso, as associações identificadas não estabelecem relações de causa e efeito.

Concluímos que a ciência de dados pode ampliar as possibilidades de análise e acompanhamento da qualidade dos vinhos, especialmente quando integrada à experiência dos especialistas. Mais do que buscar respostas definitivas, trata-se de transformar dados em informações que apoiem decisões e contribuam para valorizar as particularidades de cada vinho.